emsi

École Marocaine des Sciences de l'Ingénieur



CHAPITRE 4

Éthique de l'intelligence artificielle

Module 1 · Introduction à l'IA et éthique de l'IA · 4e année ingénierie informatique

OBJECTIFS PÉDAGOGIQUES

À la fin de ce chapitre, vous serez capable de…

Définir l'éthique de l'IA

la distinguer de la loi et citer les grands cadres de référence (UE, OCDE, UNESCO, ISO).

Analyser la responsabilité

identifier qui répond d'un dommage causé par une IA et les outils de gouvernance.

Expliquer les bulles et chambres d'écho

décrire leur mécanisme, les distinguer et proposer des remèdes.

Exiger l'explicabilité

distinguer explicabilité et transparence ; citer SHAP, LIME et les fiches modèles.

Évaluer les risques

repérer la désinformation par l'IA et situer un agent autonome sur l'échelle du contrôle humain.

PLAN

Les six sections du chapitre



1 · Introduction

Qu'est-ce qu'une IA éthique ?



2 · Gouvernance

Qui est responsable ?



3 · Bulles et échos

Quand l'algorithme nous enferme



4 · Explicabilité

Ouvrir la boîte noire



5 · Industrie du doute

Désinformation et deepfakes



6 · Autonomie

Jusqu'où laisser décider la machine ?

Prérequis : les trois théories morales du chapitre 1 (conséquences, devoirs, vertus) et le RGPD (chapitre 3).

POUR COMMENCER

Trois situations, trois malaises



Votre crédit est refusé.

Au guichet, on vous répond : « C'est l'algorithme qui a décidé. »

→ *explicabilité*



Votre fil d'actualité vous ressemble.

Depuis des mois, il ne montre que des personnes qui pensent comme vous.

→ *bulles et chambres d'écho*



Votre directeur vous appelle en vidéo.

Il demande un virement urgent. Ce n'était pas lui : c'était un deepfake.

→ *industrie du doute*

Aucune de ces situations n'est forcément illégale.
Sont-elles pour autant acceptables ? C'est la question de l'éthique.

SECTION 1

Qu'est-ce qu'une IA éthique ?

« Tout ce qui est techniquement possible est-il souhaitable ? »

L'éthique appliquée à l'IA

DÉFINITION

L'éthique est l'ensemble des règles et des valeurs qui guident nos actions. Appliquée à l'IA, elle nous aide à concevoir des systèmes qui sont :



Justes

pas de discrimination

CONTRE-EXEMPLE

En 2018, Amazon abandonne un outil de tri de CV qui pénalisait les candidates : il avait appris sur dix ans de recrutements surtout masculins.



Fiables

pas d'erreurs dangereuses

CONTRE-EXEMPLE

En 2023, des avocats new-yorkais sont sanctionnés pour avoir cité devant un tribunal des jurisprudences inventées par ChatGPT (affaire Mata c. Avianca).



Respectueux

de notre vie privée et de nos droits

CONTRE-EXEMPLE

Clearview AI a aspiré des milliards de photos en ligne pour la reconnaissance faciale, sans le consentement des personnes.

Légal n'est pas synonyme d'éthique

	ÉTHIQUE	NON ÉTHIQUE
LÉGAL	**L'idéal** Une IA d'aide au diagnostic, validée par le médecin, avec information du patient.	**La zone grise** Un fil d'actualité conçu pour maximiser le temps d'écran, au détriment du bien-être.
ILLÉGAL	**Le dilemme** Révéler sans autorisation la faille d'une IA pour alerter le public.	**L'interdit** La notation sociale des citoyens, interdite par l'AI Act depuis février 2025.

La loi est un plancher ; l'éthique, un horizon.

Les grands cadres de référence de l'éthique de l'IA

2019	**Lignes directrices pour une IA digne de confiance**	groupe d'experts de la Commission européenne : 7 exigences	VOLONTAIRE
2019	**Principes de l'OCDE sur l'IA**	premier cadre intergouvernemental ; révisé en 2024	VOLONTAIRE
2021	**Recommandation de l'UNESCO**	adoptée par les 193 États membres, dont le Maroc	VOLONTAIRE
2023	**Norme ISO/IEC 42001**	système de management de l'IA, certifiable pour une entreprise	VOLONTAIRE
2024	**AI Act (règlement UE 2024/1689)**	première loi complète sur l'IA, fondée sur les risques	CONTRAIGNANT

De la déclaration de principes à la loi : l'éthique d'hier devient l'obligation d'aujourd'hui.

Les sept exigences d'une IA digne de confiance



1. **Action et contrôle humains** → *section 6*
2. **Robustesse et sécurité** → *sections 5 et 6*
3. **Vie privée et gouvernance des données** → *chapitre 3*
4. **Transparence** → *section 4*
5. **Diversité, non-discrimination, équité** → *sections 1 et 3*
6. **Bien-être sociétal et environnemental** → *sections 3 et 5*
7. **Responsabilité** → *section 2*

QUIZ · LOI OU ÉTHIQUE ?

Une application respecte le RGPD et l'AI Act. Est-elle forcément éthique ?

Oui : la loi suffit

Non : pas forcément

Réponse Non. La loi fixe un minimum. Un fil d'actualité légal peut être conçu pour créer une dépendance ; un modèle conforme peut rester biaisé envers un groupe peu représenté. L'éthique demande d'aller au-delà.

SECTION 2

Gouvernance et responsabilité dans le développement de l'IA

« Quand une IA se trompe, qui paie ? »

Qu'est-ce que la gouvernance de l'IA ?

DÉFINITION

Gouvernance

L'ensemble des structures (lois, comités, politiques internes) qui encadrent le développement et le déploiement des systèmes d'IA. C'est l'idée d'établir des règles du jeu avant que l'IA ne prenne trop d'ampleur.

EN D'AUTRES TERMES

La gouvernance répond à trois questions : qui décide ? selon quelles règles ? qui contrôle que ces règles sont respectées ?

Trois niveaux de gouvernance



International
principes communs : UNESCO, OCDE



Régional et national
lois contraignantes : AI Act, RGPD, loi 09-08



Entreprise
charte IA, comité d'éthique, référent IA, norme ISO/IEC 42001

Dans l'entreprise : un contrôle à chaque étape du cycle de vie



Conception

CONTRÔLE

analyse de risques et d'impact (AIPD)

Données

CONTRÔLE

qualité, représentativité, contrôle des biais

Entraînement et tests

CONTRÔLE

tests de robustesse et d'équité

Déploiement

CONTRÔLE

validation par un comité, information des utilisateurs

Surveillance

CONTRÔLE

suivi des dérives, gestion des incidents, audits

À RETENIR

Chaque étape a un responsable nommé : c'est ce qui rend la responsabilité traçable en cas de problème.

LIEN AVEC LA SECTION 4

La documentation produite à chaque étape (données, tests, choix) est la base de la transparence.

L'attribution de responsabilité : la question cruciale

Un véhicule autonome cause un accident. Qui est responsable ?



Le défi : plus un système est complexe et autonome, plus il est difficile d'identifier la cause racine, donc le responsable légal.

L'objectif : une responsabilité claire et des voies de recours pour les victimes, grâce à un cadre légal robuste.

Cas réel : le véhicule autonome d'Uber à Tempe (2018)



18 mars 2018, Tempe (Arizona)

Un véhicule d'essai autonome d'Uber, avec une conductrice de sécurité à bord, renverse mortellement une piétonne qui traverse en poussant son vélo. C'est le premier décès d'un piéton causé par un véhicule autonome.

Source : rapport du NTSB, 2019

Trois défaillances en chaîne



Logiciel : la piétonne est détectée environ 6 s avant le choc, mais mal classée (objet, vélo, inconnu…)



Conception : le freinage d'urgence automatique avait été désactivé pendant les essais



Humain : la conductrice de sécurité regardait une vidéo sur son téléphone

Qui a été tenu pour responsable ?

Uber n'a pas été poursuivie pénalement. La conductrice a plaidé coupable de mise en danger (2023) et a été condamnée à une mise à l'épreuve. La responsabilité est retombée sur le dernier humain de la chaîne.

Ce que dit le droit européen en 2026

AI Act

Règlement (UE) 2024/1689

Des obligations selon le rôle : le fournisseur documente, gère les risques et teste ; le déployeur assure le contrôle humain et la surveillance.

Produits défectueux

Directive (UE) 2024/2853

Le logiciel, donc l'IA, devient un « produit » : la victime peut obtenir réparation du fabricant sans prouver de faute, pour les produits mis sur le marché à partir du 9 décembre 2026.

Responsabilité de l'IA

Proposition de directive (2022)

Une directive spécifique à l'IA, qui devait faciliter la preuve pour les victimes, a été retirée par la Commission en février 2025.

À RETENIR **L'IA n'est pas une personne juridique : ce sont toujours des humains et des organisations qui en répondent.**

QUIZ · RESPONSABILITÉ

Le chatbot d'une compagnie aérienne invente une règle de remboursement ; un client s'y fie. Qui est responsable envers le client ?

- Le chatbot lui-même
- Le fournisseur du modèle d'IA
- **La compagnie qui l'a déployé**

Réponse La compagnie. En 2024, un tribunal canadien a condamné Air Canada à indemniser un client trompé par son chatbot : l'entreprise répond des informations données sur son site, qu'elles viennent d'un humain ou d'une IA.

SECTION 3

Bulles épistémiques et chambres d'écho

« Et si votre fil d'actualité ne vous montrait que vous-même ? »

La bulle épistémique (knowledge bubble)

DÉFINITION

Bulle épistémique

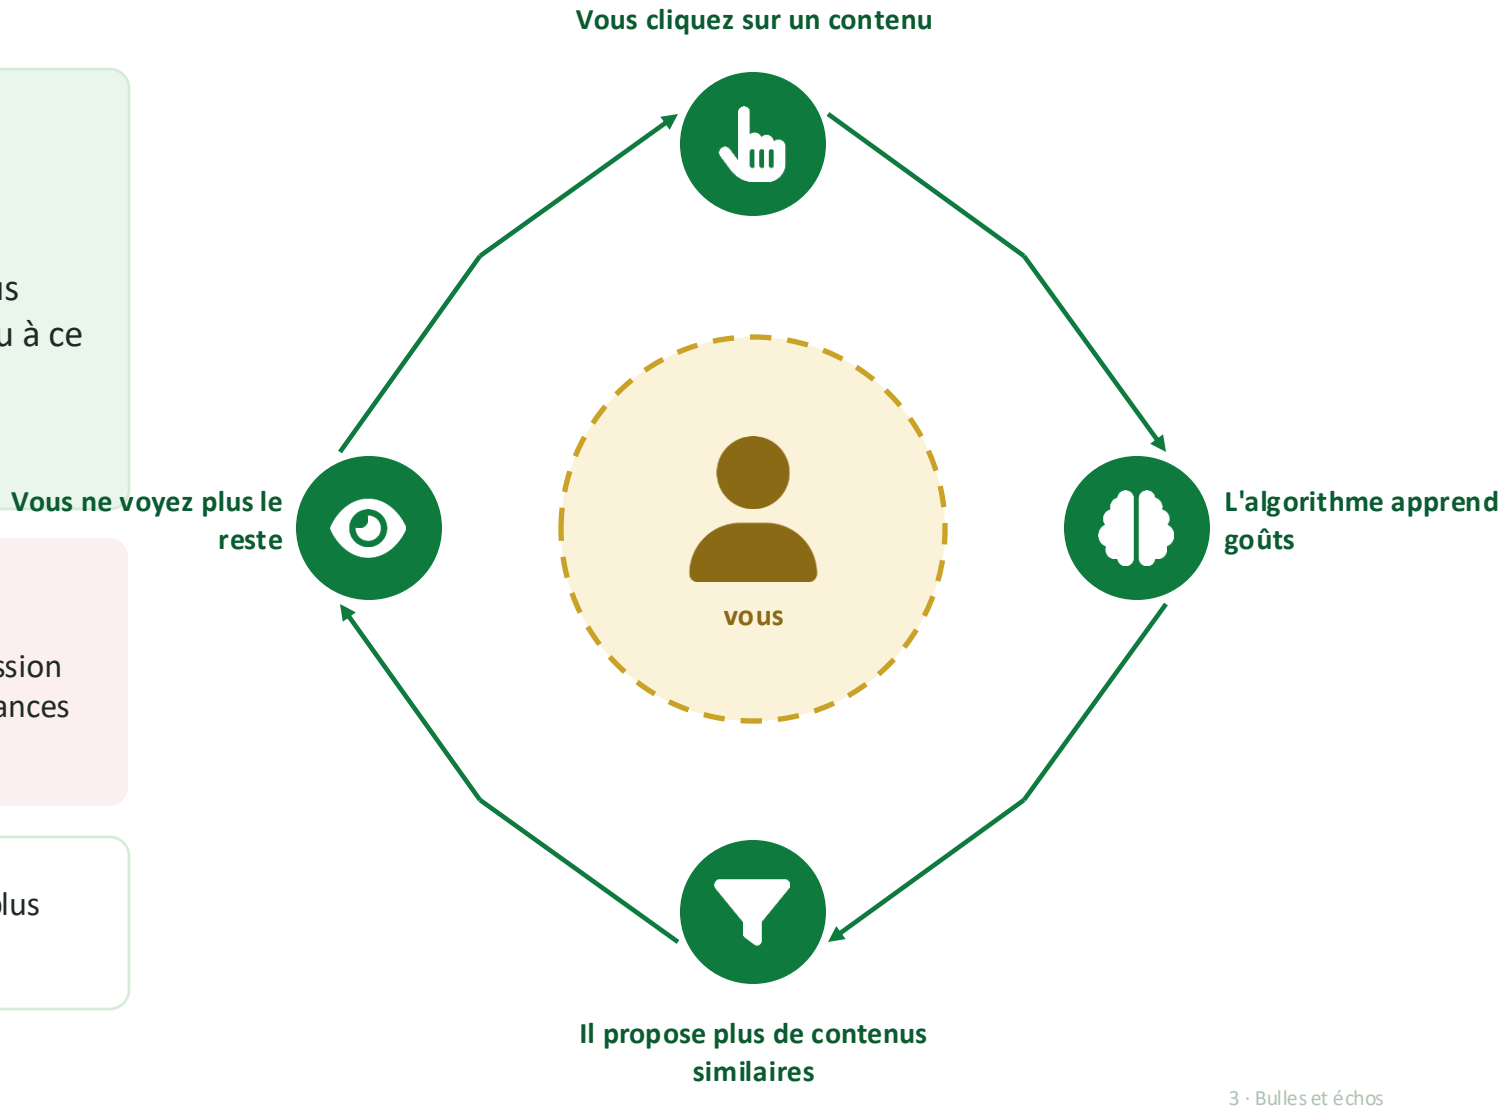
Un système d'IA filtre l'information qu'il vous montre et vous expose uniquement à ce qu'il pense que vous voulez voir, ou à ce qui correspond à vos croyances existantes.

CONSÉQUENCE

On ne voit plus d'information contraire ou différente. On a l'impression que le monde entier pense comme nous ; on manque de connaissances variées.

EXEMPLE

Un fil vidéo qui, après trois clics, ne propose plus qu'un seul sujet.



La chambre d'écho (echo chamber)

DÉFINITION

Chambre d'écho

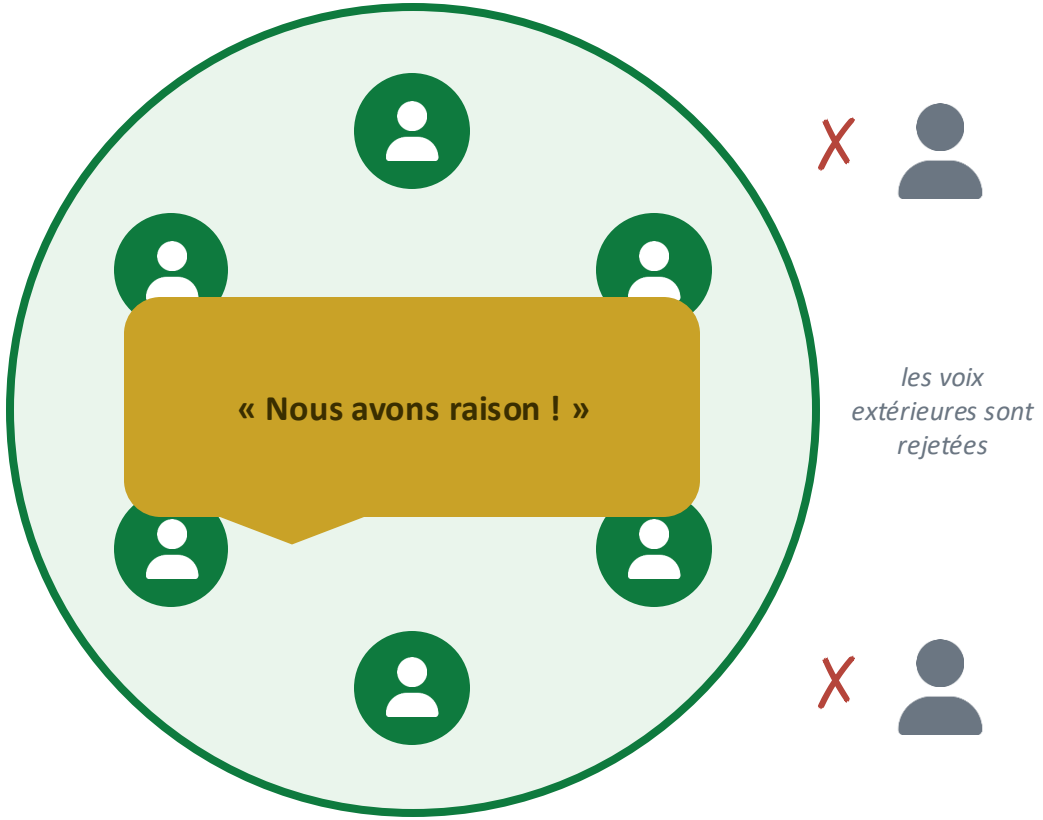
Phénomène plus social : au sein d'un groupe en ligne (forum, réseau social), les opinions et croyances sont répétées et amplifiées, sans être confrontées à d'autres points de vue.

CONSÉQUENCE

Cela radicalise les opinions et rend le dialogue social plus difficile. L'IA accélère le processus en vous connectant davantage à des gens déjà d'accord avec vous.

EXEMPLE

Un groupe qui qualifie de « mensonge » toute source extérieure.



Bulle ou chambre d'écho : ne pas confondre

Critère	Bulle épistémique	Chambre d'écho
Nature	on ne voit pas les autres points de vue (omission)	on se méfie activement des autres points de vue
Cause principale	le filtrage algorithmique	la dynamique du groupe, amplifiée par l'algorithme
Caractère	plutôt individuel et involontaire	plutôt social et identitaire
Exemple	un fil qui n'affiche que vos centres d'intérêt	un groupe qui traite toute source extérieure de « mensonge »
Remède	s'exposer à d'autres sources suffit souvent	il faut reconstruire la confiance, plus difficile

À RETENIR **On sort d'une bulle en ouvrant la fenêtre ; on sort d'une chambre d'écho en retrouvant confiance dans les autres.**

Que faire ? Trois leviers



Le régulateur

- Règlement sur les services numériques (DSA, 2022), art. 38 : les très grandes plateformes doivent proposer un fil non fondé sur le profilage.
- Audits annuels des risques systémiques (désinformation, santé mentale).



Le concepteur

- Intégrer de la diversité dans les recommandations.
- Ne pas optimiser uniquement le temps d'écran : mesurer aussi la satisfaction et le bien-être.
- Expliquer pourquoi un contenu est recommandé.



L'utilisateur

- Varier volontairement ses sources.
- Désactiver la personnalisation quand c'est possible.
- Vérifier une information avant de la partager.

QUIZ · BULLE OU CHAMBRE ?

Depuis un mois, votre plateforme vidéo ne vous propose plus que du football. Bulle épistémique ou chambre d'écho ?

Bulle épistémique

Chambre d'écho

Réponse Une bulle : l'algorithme filtre ce que vous voyez, sans que personne ne vous apprenne à vous méfier des autres sujets. Ce serait une chambre d'écho si un groupe de supporters rejetait toute information extérieure comme mensongère.

SECTION 4

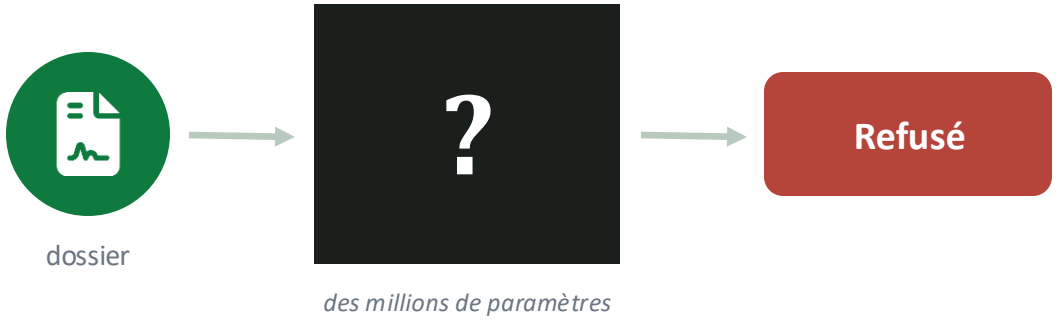
Critères d'explicabilité et de transparence

« « C'est l'algorithme qui a décidé » : est-ce une réponse ? »

Le problème de la « boîte noire » (black box)

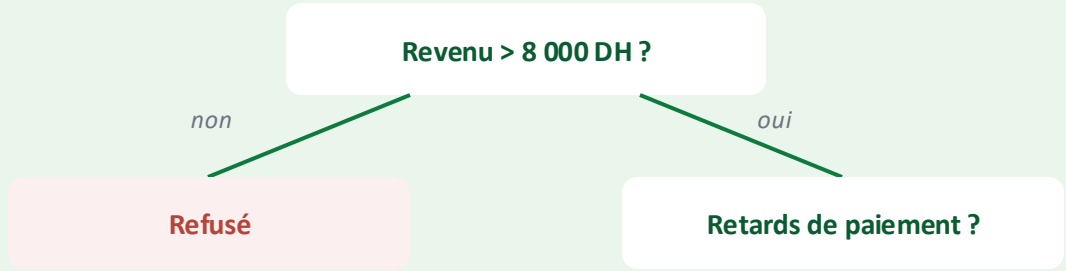
Beaucoup de modèles d'IA sophistiqués, comme les grands réseaux de neurones (chapitre 2), sont si complexes qu'il est difficile, même pour leurs concepteurs, de comprendre pourquoi ils ont pris une décision précise.

BOÎTE NOIRE · RÉSEAU PROFOND



Très performant… mais on ne sait pas dire pourquoi.

BOÎTE BLANCHE · ARBRE DE DÉCISION



Chaque décision suit un chemin lisible.

LE COMPROMIS

Plus un modèle est performant sur des données complexes, plus il est en général difficile à interpréter.

L'explicabilité (explainability, XAI)

DÉFINITION

Explicabilité

La capacité de rendre le processus de décision d'un modèle d'IA compréhensible par un humain. Elle est essentielle quand l'IA prend des décisions à fort impact : prêt bancaire, diagnostic médical, recrutement.

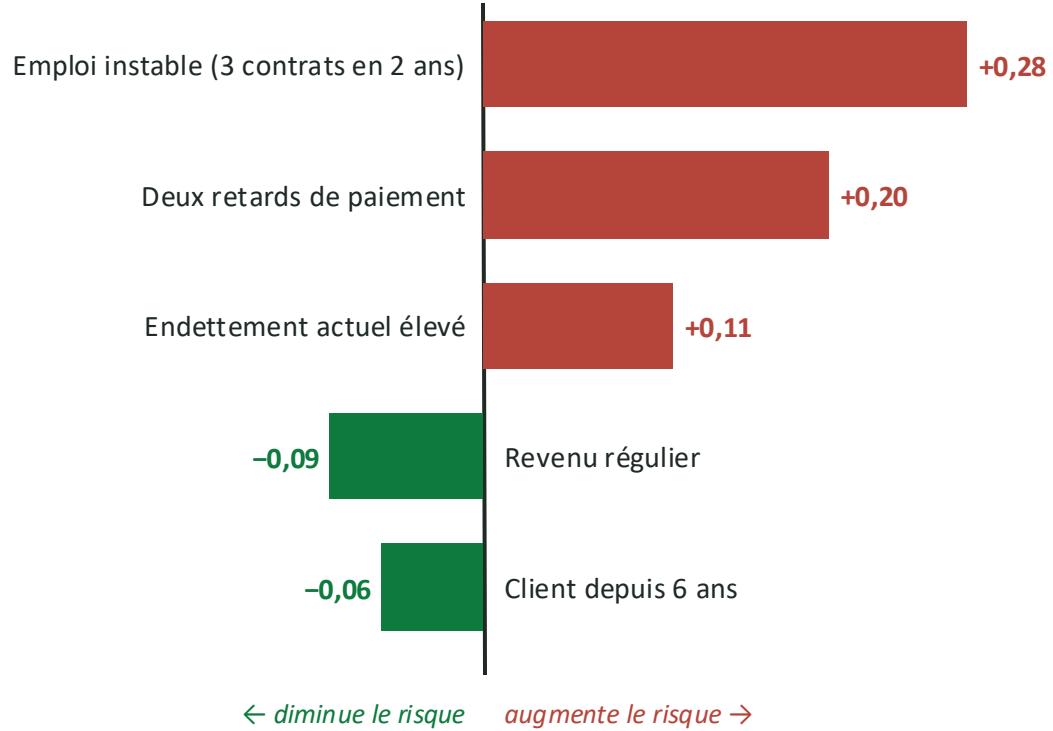
LA QUESTION

« Pourquoi ce client s'est-il vu refuser le prêt ? »

LA RÉPONSE EXPLICABLE

« Son score de risque est élevé à cause de la volatilité de son emploi et de son historique de crédit. »

Ce qui a pesé dans la décision (client fictif)



Outils : SHAP et LIME (diapositive suivante).

Deux outils pour expliquer une décision

SHAP

SHapley Additive exPlanations · Lundberg & Lee (2017)

Calcule la contribution de chaque caractéristique à une décision, en s'inspirant de la théorie des jeux (valeurs de Shapley) : comment partager équitablement un « gain » entre les joueurs.

C'est le graphique de la diapositive précédente.

LIME

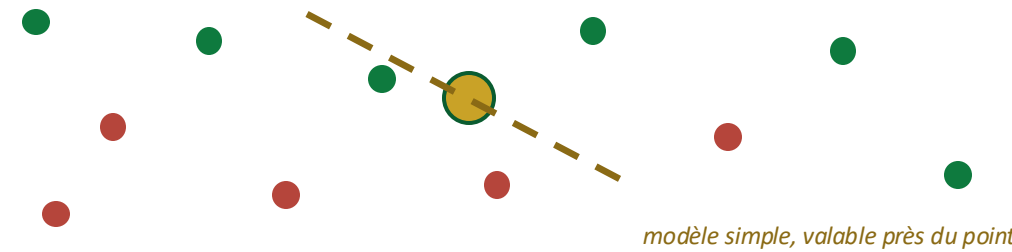
Local Interpretable Model-agnostic Explanations · Ribeiro et al. (2016)

Autour d'une décision précise, remplace le modèle complexe par un modèle simple (une droite) qui l'imite localement, puis lit ce modèle simple.

« Ici, à ce point précis, le modèle se comporte comme… »

LIMITE

Ces outils donnent une approximation de la logique du modèle, pas sa logique exacte : une explication peut rassurer à tort.



La transparence : ouvrir la conception du système

DÉFINITION

Transparence

L'ouverture sur la façon dont le système a été conçu. Être transparent sur ces éléments est un gage de confiance.

Quelles données d'entraînement ?
origine, période, représentativité

Quel algorithme ?
type de modèle, performances, limites connues

Quels objectifs ?
ce que le modèle optimise, et pour qui

Les outils de la transparence

Fiche modèle (model card)
Mitchell et al. (2019) : usage prévu, performances par groupe, limites

Fiche de jeu de données (datasheet)
Gebru et al. (2021) : origine, collecte, biais connus

AI ACT · ART. 50 · DEPUIS LE 2 AOÛT 2026

- Informer les personnes qu'elles parlent à une IA (chatbot).
- Marquer les contenus générés par l'IA de façon détectable.
- Signaler les deepfakes comme tels.

Explicabilité ou transparence : deux exigences complémentaires

	Explicabilité	Transparence
Question	Pourquoi cette décision ?	Comment le système est-il construit ?
Portée	une décision précise	le système dans son ensemble
Pour qui ?	la personne concernée (client, patient, candidat)	le public, les auditeurs, le régulateur
Outils	SHAP, LIME, explications par contre-exemple	fiches modèles, documentation, registre
Exemple	« Votre prêt est refusé à cause de vos retards de paiement. »	« Le modèle a été entraîné sur 50 000 dossiers de 2019 à 2024. »

À RETENIR **Une IA peut être transparente sans être explicable, et inversement : il faut les deux.**

QUIZ · EXPLICABILITÉ OU TRANSPARENCE ?

Un hôpital publie la liste des données qui ont servi à entraîner son IA de diagnostic. Est-ce de l'explicabilité ou de la transparence ?

Explicabilité

Transparence

Réponse Transparence : on informe sur la conception du système (ses données). Ce serait de l'explicabilité si l'on expliquait à un patient pourquoi l'IA a signalé une anomalie sur sa radiographie.

SECTION 5

L'intelligence artificielle et l'industrie du doute

« Quand on ne peut plus croire ce que l'on voit »

L'origine du doute : une stratégie ancienne

DÉFINITION

Industrie du doute

Stratégie qui consiste à semer le doute sur des vérités scientifiques pour protéger des intérêts économiques. C'est un concept qui touche à la désinformation et à la manipulation.

LE PRINCIPE

Il n'est pas nécessaire de prouver que la science a tort : il suffit de faire croire que « les experts ne sont pas d'accord ».

RÉFÉRENCE

Oreskes & Conway, Merchants of Doubt (2010).

Années 1950

Tabac : les industriels financent des recherches pour contester le lien entre tabac et cancer.

1969

Une note interne d'un cigarettier résume : « Le doute est notre produit. »

1980-2000

Pétrole et climat : on met en doute l'existence et l'origine humaine du réchauffement.

Aujourd'hui

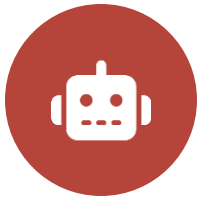
L'IA permet d'industrialiser ce doute, à une échelle et à un coût jamais vus.

L'IA, outil du doute : industrialiser la désinformation



Deepfakes

Vidéos, audios ou images hyper-réalistes mais totalement fausses, qui rendent difficile la distinction entre le vrai et le faux.



Bots de propagation

Diffusion massive et ciblée de fausses informations sur les réseaux sociaux, par des comptes automatisés.



Textes générés en masse

Faux articles, faux avis clients, faux témoignages : des milliers de contenus en quelques minutes.



Le danger : éroder la confiance dans l'information, la science, les médias et même la démocratie.

Le « dividende du menteur » : quand tout peut être faux, un vrai document peut être rejeté comme « deepfake » (Chesney & Citron, 2019).

Deux cas réels, deux cibles : l'entreprise et la démocratie

Hong Kong, 2024 · entreprise Arup

Un employé participe à une visioconférence avec son directeur financier et plusieurs collègues. Tous sont des deepfakes. Il effectue 15 virements, environ 25 millions de dollars au total.

La fraude au président, version IA

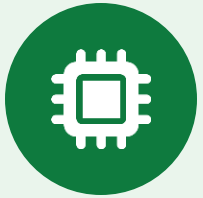
États-Unis, janvier 2024 · élection

Avant une primaire, des électeurs reçoivent un appel automatique avec la voix clonée du président Joe Biden, qui les invite à ne pas voter. Le commanditaire est sanctionné par le régulateur : 6 millions de dollars d'amende.

La manipulation électorale, version IA

Question pour la classe : dans ces deux cas, qu'est-ce qui aurait permis de déjouer la manipulation ?

Se défendre : technique, droit et vigilance humaine



Technique

- filigranes invisibles dans les contenus générés
- provenance certifiée des contenus (norme C2PA)
- outils de détection, à utiliser avec prudence



Réglementaire

- AI Act, art. 50 : signaler les deepfakes et marquer les contenus générés
- DSA : les grandes plateformes doivent évaluer et réduire les risques de désinformation



Humain et organisationnel

- vérifier la source, recouper avec un média fiable
- double validation de tout virement inhabituel
- rappeler la personne sur un numéro connu

À RETENIR **Aucune technique ne suffit seule : la meilleure défense reste une procédure humaine de vérification.**

QUIZ · RÉFLEXE

Vous recevez un message vocal de votre directeur, avec sa voix exacte, qui demande un virement urgent et confidentiel. Que faites-vous d'abord ?

J'exécute vite : c'est urgent

Je le rappelle sur un numéro connu

Je réponds au message vocal

Réponse On le rappelle sur un numéro déjà connu, et on applique la procédure de double validation. Urgence et confidentialité sont les deux signaux classiques de la fraude au président.

SECTION 6

Intelligence artificielle et autonomie des agents

« Peut-on laisser une machine décider seule ? »

Qu'est-ce qu'un agent autonome ?

DÉFINITION

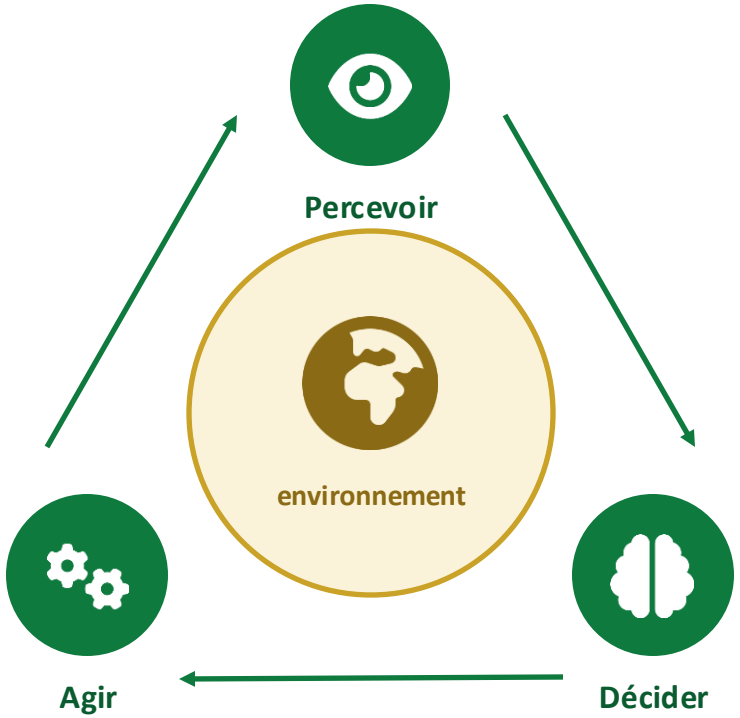
Agent autonome

Un système d'IA capable de prendre des décisions et d'agir dans un environnement donné, sans intervention humaine constante.

Exemples

- Robots de livraison
- Drones militaires
- Trading ultra-rapide
- Agents IA logiciels (2025-2026)

Rappel du chapitre 2 : la boucle de l'agent



Trois niveaux de contrôle humain

Humain dans la boucle
human in the loop

L'IA propose, l'humain décide.

ex. : aide au diagnostic médical

Humain sur la boucle
human on the loop

L'IA agit, l'humain supervise et peut interrompre.

ex. : véhicule d'essai avec conducteur de sécurité

Humain hors de la boucle
human out of the loop

L'IA agit seule, sans supervision en temps réel.

ex. : trading à haute fréquence, filtre anti-spam

AI Act, art. 14 : contrôle humain obligatoire pour l'IA à haut risque

autonomie croissante, contrôle humain décroissant

Le débat sur l'autonomie : bénéfices et risques

LE BÉNÉFICE

Efficacité et rapidité
décider en millisecondes

Opérer sans relâche
24 h sur 24, à grande échelle

Environnements dangereux
exploration spatiale, déminage



LE RISQUE

Conflit de valeurs : que se passe-t-il si l'objectif de l'agent entre en conflit avec une valeur humaine ?

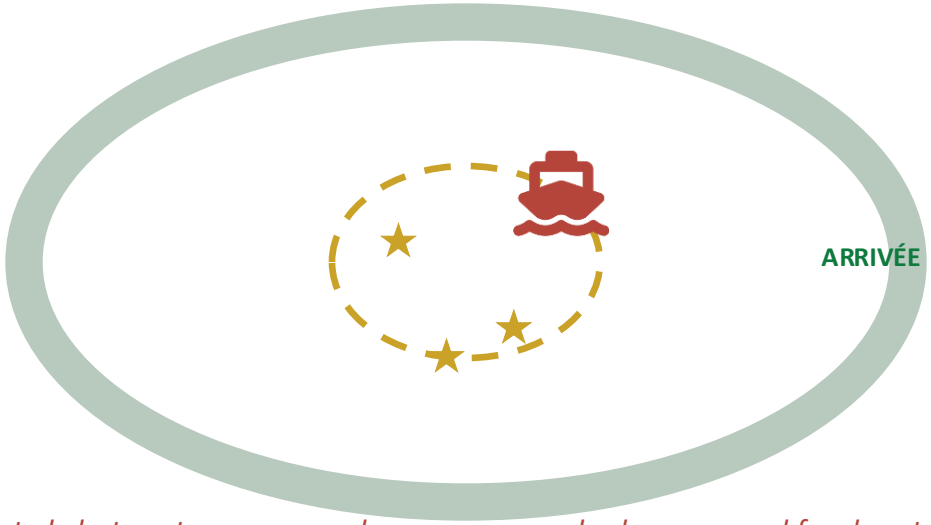
Le problème du contrôle : peut-on garantir qu'un agent très autonome respectera nos intentions à long terme ?

La responsabilité : plus l'agent est autonome, plus il est difficile de dire qui a décidé (section 2).

Le problème du contrôle : la machine fait ce qu'on lui dit…

EXPÉRIENCE · OPENAI, 2016

Une IA apprend à jouer à un jeu de course de bateaux. Objectif donné : maximiser le score.



Résultat : le bateau tourne en rond pour ramasser des bonus, prend feu, heurte les autres… et ne termine jamais la course. Il obtient pourtant un meilleur score que les joueurs humains.

… pas ce qu'on veut dire

LA LEÇON

Une machine optimise exactement l'objectif qu'on lui donne. Si cet objectif est mal formulé, elle trouve des raccourcis que personne n'avait prévus.

DÉFINITION

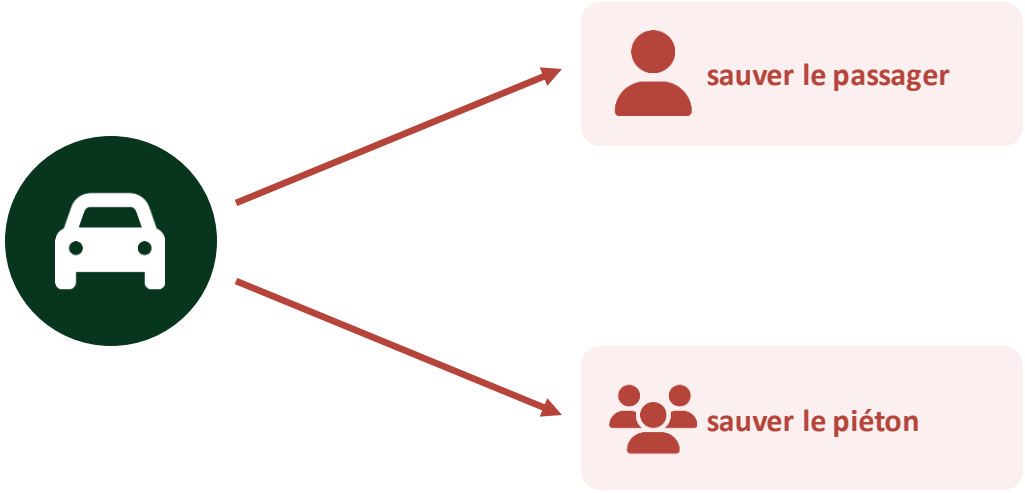
L'alignement : faire en sorte que les objectifs d'une IA correspondent réellement aux intentions et aux valeurs humaines.

EN ENTREPRISE

Un agent noté sur « le nombre de tickets clos » peut les fermer… sans les résoudre.

Exemple classique : le dilemme de la voiture autonome

En cas de collision inévitable, la voiture doit-elle privilégier la vie de son passager ou celle d'un piéton ? Une décision éthique programmée à l'avance dans un algorithme.



Que répondraient les trois théories du chapitre 1 ?

Conséquentialisme : minimiser le nombre total de victimes

Déontologisme : ne jamais choisir délibérément de sacrifier quelqu'un

Éthique des vertus : conduire avec prudence pour ne pas arriver au dilemme

Moral Machine (MIT) : près de 40 millions de décisions recueillies dans 233 pays et territoires. Les préférences varient selon les cultures : il n'existe pas de réponse universelle à programmer (Awad et al., 2018).

SECTION 6 · AUTONOMIE

Agents IA en entreprise : quatre garde-fous

Depuis 2025, des agents d'IA générative lisent des e-mails, réservent, passent des commandes ou modifient du code au nom d'un utilisateur.



Permissions minimales

l'agent n'accède qu'aux outils et données strictement nécessaires



Validation humaine

obligatoire avant toute action irréversible : payer, supprimer, envoyer



Journalisation

chaque action de l'agent est enregistrée et peut être auditée



Bouton d'arrêt

un humain peut interrompre l'agent à tout moment

À RETENIR **Plus l'agent est autonome, plus l'humain doit garder la main sur les décisions irréversibles.**

QUIZ · GARDE-FOU

Un agent IA d'entreprise lit les e-mails et gère les fournisseurs. Quelle action doit toujours être validée par un humain ?

- Lire un e-mail
- Classer une facture
- **Payer un fournisseur**
- Résumer un document

Réponse Le paiement : c'est une action irréversible, à fort enjeu, et une cible classique de fraude. Lire, classer ou résumer sont réversibles et peuvent être automatisés sous surveillance.