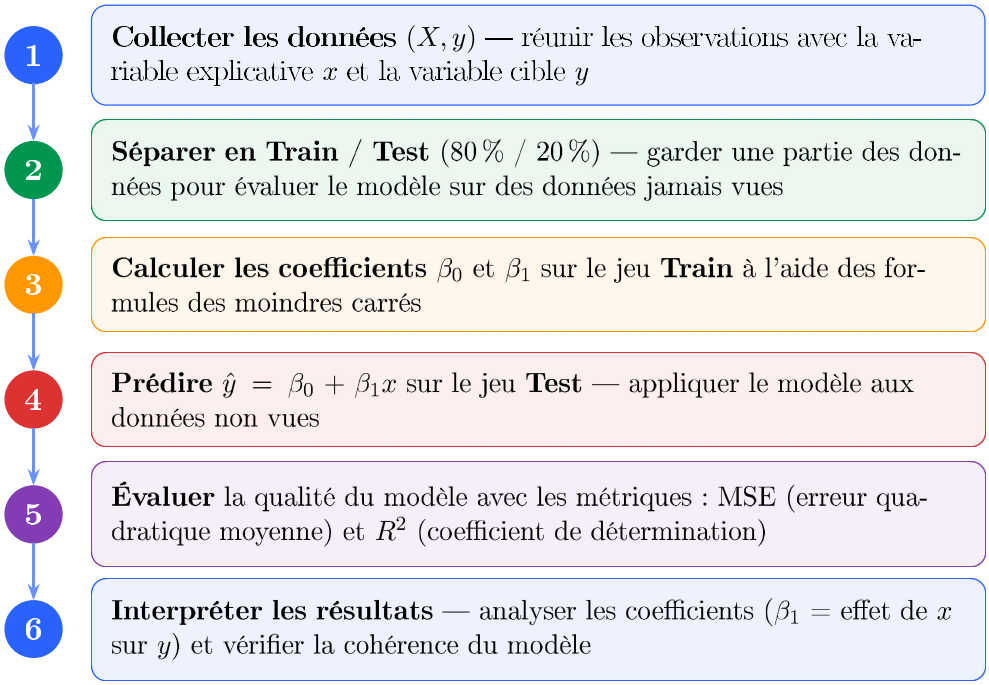


FIGURE 4.3 – Les 6 étapes pour appliquer la régression linéaire simple, de la collecte des données à l'interprétation.

4.3 Dérivation mathématique complète

Nous allons maintenant construire les mathématiques de la régression linéaire **pas à pas**, en n'oubliant aucune étape. Même si vous n'avez jamais fait de calcul différentiel, vous pourrez suivre.

4.3.1 L'équation du modèle

Modèle de régression linéaire simple

Le modèle de régression linéaire simple suppose que la relation entre x (variable explicative) et y (variable à prédire) peut être approximée par une **droite** :

$$\boxed{\hat{y} = \beta_0 + \beta_1 x}$$

où :

- $\hat{y}$ (lire « y chapeau ») est la **valeur prédite** par le modèle.
- β_0 est l'**ordonnée à l'origine** (intercept) : la valeur de $\hat{y}$ quand $x = 0$.
- β_1 est la **pente** (slope) : de combien $\hat{y}$ augmente quand x augmente de 1.
- x est la **variable explicative** (ex : la surface en m^2).

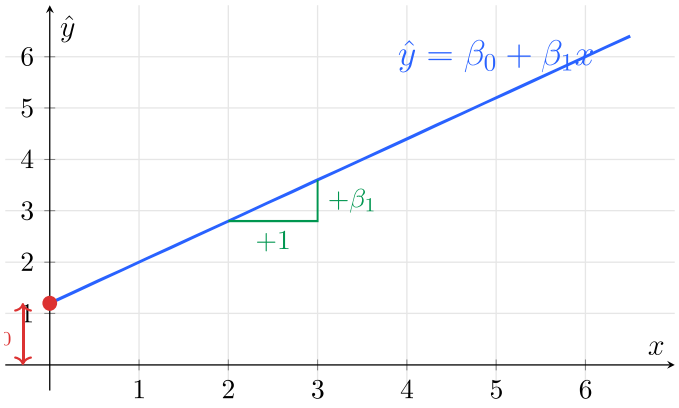


FIGURE 4.4 – Interprétation géométrique de β_0 (intercept) et β_1 (pente).

Interprétation concrète

Si notre modèle est $\hat{y} = 17 + 2{,}6\,x$ (prix en milliers d'euros, surface en m^2) :

- $\beta_0 = 17$: un appartement de 0 m^2 coûterait 17 000 € (c'est le « coût de base », même s'il n'a pas de sens physique ici).
- $\beta_1 = 2{,}6$: chaque mètre carré supplémentaire ajoute 2 600 € au prix.
- Pour 73 m^2 : $\hat{y} = 17 + 2{,}6 \times 73 = 17 + 189{,}8 = 206{,}8$ milliers d'euros, soit environ **206 800 €**.

4.3.2 L'erreur (résidu)

En pratique, les points ne sont **jamais exactement sur la droite.** Il y a toujours un écart entre la valeur réelle y_i et la valeur prédite $\hat{y}_i$. Cet écart s'appelle le **résidu.**

Résidu (erreur)

Pour chaque observation i, le résidu est défini par :

$$\boxed{e_i = y_i - \hat{y}_i = y_i - (\beta_0 + \beta_1 x_i)}$$

- Si $e_i > 0$: le modèle **sous-estime** (la vraie valeur est au-dessus de la droite).
- Si $e_i < 0$: le modèle **surestime** (la vraie valeur est en dessous de la droite).
- Si $e_i = 0$: le modèle prédit **parfaitement** ce point.

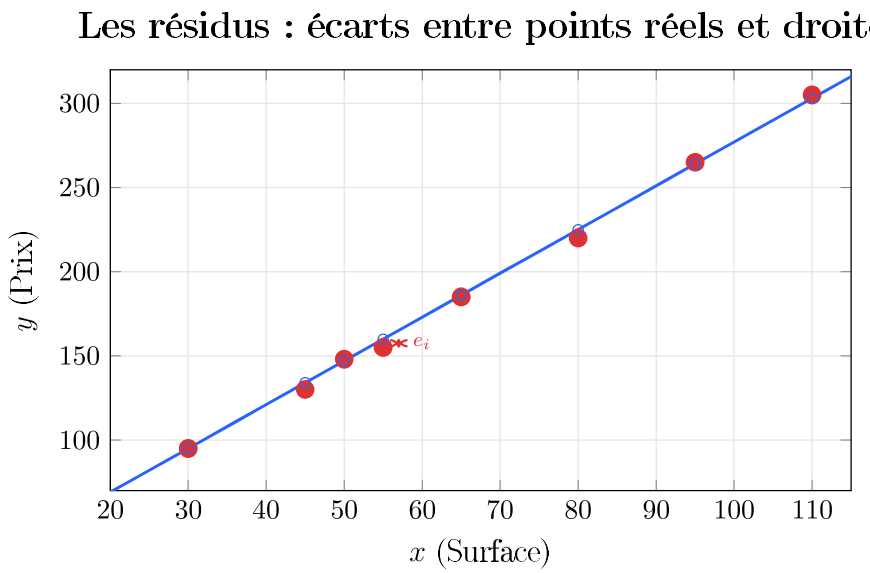


FIGURE 4.5 – Chaque ligne rouge verticale représente un résidu $e_i = y_i - \hat{y}_i$.

4.3.3 Pourquoi les erreurs au carré ? (Très important !)

Notre objectif est de trouver β_0 et β_1 qui rendent les résidus **les plus petits possible**. Mais comment mesurer la « taille globale » des erreurs ? Examinons trois idées.

Idée 1 : la somme simple des erreurs

Pourquoi ne pas simplement additionner toutes les erreurs ?

$$\sum_{i=1}^{n} e_i = \sum_{i=1}^{n} (y_i - \hat{y}_i)$$

Problème : les erreurs s'annulent !

Prenons un exemple simple avec 4 points :

Point	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$
1	10	8	$+2$
2	5	8	-3
3	12	11	$+1$
4	7	9	-2
		Somme :	$+2 - 3 + 1 - 2 = \mathbf{-2}$

La somme est presque zéro, alors que les erreurs individuelles sont grandes ! Les erreurs positives et négatives se **compensent**. Cette mesure est donc **inutile.**

Idée 2 : la somme des valeurs absolues

On pourrait prendre la valeur absolue de chaque erreur :

$$\sum_{i=1}^{n} |e_i| = |+2| + |-3| + |+1| + |-2| = 2 + 3 + 1 + 2 = 8$$

C'est mieux ! Mais la valeur absolue pose un problème mathématique : elle n'est **pas dérivable** en zéro (la courbe fait un « coin » pointu). Or nous aurons besoin de dérivées pour trouver le minimum.

Idée 3 : la somme des erreurs au carré (la bonne !)

On met chaque erreur **au carré** :

$$\sum_{i=1}^{n} e_i^2 = (+2)^2 + (-3)^2 + (+1)^2 + (-2)^2 = 4 + 9 + 1 + 4 = 18$$

Pourquoi le carré est idéal

La mise au carré possède trois avantages majeurs :

1. **Toujours positif** : $e_i^2 \geq 0$, donc pas de compensation.
2. **Dérivable partout** : la fonction $f(x) = x^2$ est lisse, ce qui permet de trouver le minimum par calcul.
3. **Pénalise les grandes erreurs** : une erreur de 3 compte pour 9 (au lieu de 3), une erreur de 10 compte pour 100. Les grandes erreurs sont « punies » beaucoup plus.

4.3.4 La fonction de coût $J(\beta_0, \beta_1)$

Nous avons maintenant tous les ingrédients pour définir ce que nous voulons minimiser.

Fonction de coût — Moindres carrés

La **fonction de coût** (ou fonction objectif) de la régression linéaire est :

$$\boxed{J(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2}$$

Notre objectif est de trouver les valeurs de β_0 et β_1 qui **minimisent** J.

Développons pour bien comprendre ce que contient cette somme :

$$\begin{aligned} J(\beta_0, \beta_1) = &(y_1 - \beta_0 - \beta_1 x_1)^2 \\ &+ (y_2 - \beta_0 - \beta_1 x_2)^2 \\ &+ \cdots \\ &+ (y_n - \beta_0 - \beta_1 x_n)^2 \end{aligned}$$

Que veut dire « minimiser » ?

Imaginez que $J(\beta_0, \beta_1)$ est une surface en 3D (un bol ou une cuvette). L'axe horizontal représente β_0, l'autre axe horizontal représente β_1, et la hauteur représente la valeur de J (l'erreur totale).
Minimiser J, c'est trouver le **fond de la cuvette** : le point le plus bas, où l'erreur est la plus petite possible. C'est là que se trouvent les « meilleures » valeurs de β_0 et β_1.

4.3.5 Rappel : qu'est-ce qu'une dérivée ?

Avant de calculer les dérivées, rappelons ce qu'est une dérivée pour ceux qui ne l'ont jamais vue.

Dérivée — explication intuitive

La **dérivée** d'une fonction en un point vous dit **dans quelle direction et à quelle vitesse** la fonction monte ou descend en ce point. C'est la **pente** de la courbe.

- Si la dérivée est **positive** (> 0) : la fonction monte ↗ (on peut encore descendre en allant à gauche).
- Si la dérivée est **négative** (< 0) : la fonction descend ↘ (on peut encore descendre en allant à droite).
- Si la dérivée est **nulle** ($= 0$) : on est **au fond de la vallée** (ou au sommet d'une colline). C'est un **extremum**.

Règles de dérivation utiles (les seules dont nous aurons besoin) :

$$\frac{d}{dx}(c) = 0 \quad \text{(la dérivée d'une constante est zéro)}$$

$$\frac{d}{dx}(x) = 1$$

$$\frac{d}{dx}(x^2) = 2x$$

$$\frac{d}{dx}\big(f(g(x))\big) = f'(g(x)) \cdot g'(x) \quad \text{(règle de la chaîne)}$$

La règle de la chaîne en français simple

La **règle de la chaîne** dit simplement : si on a une « fonction dans une fonction » (comme $(3x+5)^2$), on dérive « l'extérieur » d'abord, puis on multiplie par la dérivée de « l'intérieur ».

Exemple : dériver $(3x+5)^2$:

1. L'extérieur c'est $(\ldots)^2$, sa dérivée est $2(\ldots) = 2(3x+5)$.
2. L'intérieur c'est $3x+5$, sa dérivée est 3.
3. Résultat : $2(3x+5) \times 3 = 6(3x+5)$.

4.3.6 Dérivée partielle par rapport à β_0

Une **dérivée partielle** est exactement comme une dérivée normale, sauf qu'on ne dérive que par rapport à **une seule variable** en traitant les autres comme des constantes.

Calculons $\dfrac{\partial J}{\partial \beta_0}$:

$$\frac{\partial J}{\partial \beta_0} = \frac{\partial}{\partial \beta_0} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

La dérivée d'une somme est la somme des dérivées :

$$= \sum_{i=1}^{n} \frac{\partial}{\partial \beta_0} (y_i - \beta_0 - \beta_1 x_i)^2$$

Appliquons la **règle de la chaîne** sur chaque terme. Posons $u_i = y_i - \beta_0 - \beta_1 x_i$, donc on dérive $(u_i)^2$ par rapport à β_0 :

— Dérivée de l'extérieur : $\dfrac{d}{du}(u^2) = 2u = 2(y_i - \beta_0 - \beta_1 x_i)$

— Dérivée de l'intérieur par rapport à β_0 : $\dfrac{\partial u_i}{\partial \beta_0} = \dfrac{\partial}{\partial \beta_0}(y_i - \beta_0 - \beta_1 x_i) = -1$

En multipliant (règle de la chaîne) :

$$\frac{\partial J}{\partial \beta_0} = \sum_{i=1}^{n} 2(y_i - \beta_0 - \beta_1 x_i) \times (-1)$$

$$= \boxed{-2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)}$$

4.3.7 Dérivée partielle par rapport à β_1

De la même manière, calculons $\dfrac{\partial J}{\partial \beta_1}$:

$$\frac{\partial J}{\partial \beta_1} = \sum_{i=1}^{n} \frac{\partial}{\partial \beta_1}(y_i - \beta_0 - \beta_1 x_i)^2$$

Appliquons la règle de la chaîne avec $u_i = y_i - \beta_0 - \beta_1 x_i$:

— Dérivée de l'extérieur : $2(y_i - \beta_0 - \beta_1 x_i)$

— Dérivée de l'intérieur par rapport à β_1 : $\dfrac{\partial u_i}{\partial \beta_1} = \dfrac{\partial}{\partial \beta_1}(y_i - \beta_0 - \beta_1 x_i) = -x_i$

En multipliant :

$$\frac{\partial J}{\partial \beta_1} = \sum_{i=1}^{n} 2(y_i - \beta_0 - \beta_1 x_i) \times (-x_i)$$

$$= \boxed{-2 \sum_{i=1}^{n} x_i (y_i - \beta_0 - \beta_1 x_i)}$$

4.3.8 Résolution du système (trouver β_0 et β_1)

Pour trouver le minimum, on met les deux dérivées égales à zéro :

$$\frac{\partial J}{\partial \beta_0} = 0 \quad \text{et} \quad \frac{\partial J}{\partial \beta_1} = 0$$

Équation 1 : $\dfrac{\partial J}{\partial \beta_0} = 0$

$$-2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0 \quad \text{(on divise par } -2\text{)}$$

$$\sum_{i=1}^{n} y_i - \sum_{i=1}^{n} \beta_0 - \beta_1 \sum_{i=1}^{n} x_i = 0 \quad \text{(on distribue la somme)}$$

$$\sum_{i=1}^{n} y_i - n\beta_0 - \beta_1 \sum_{i=1}^{n} x_i = 0 \quad \left(\text{car } \sum_{i=1}^{n} \beta_0 = n\beta_0\right)$$

Divisons tout par n :

$$\frac{1}{n}\sum_{i=1}^{n} y_i - \beta_0 - \beta_1 \cdot \frac{1}{n}\sum_{i=1}^{n} x_i = 0$$

$$\bar{y} - \beta_0 - \beta_1 \bar{x} = 0 \quad (\text{car } \frac{1}{n}\sum x_i = \bar{x} \text{ et } \frac{1}{n}\sum y_i = \bar{y})$$

Donc :

$$\boxed{\beta_0 = \bar{y} - \beta_1 \bar{x}} \tag{4.1}$$

Interprétation

Cette formule nous dit que la **droite de régression passe toujours par le point moyen** $(\bar{x}, \bar{y})$. C'est une propriété remarquable !

Équation 2 : $\dfrac{\partial J}{\partial \beta_1} = 0$

$$-2\sum_{i=1}^{n} x_i(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^{n} x_i(y_i - \beta_0 - \beta_1 x_i) = 0 \quad (\text{on divise par } -2)$$

$$\sum_{i=1}^{n} x_i y_i - \beta_0 \sum_{i=1}^{n} x_i - \beta_1 \sum_{i=1}^{n} x_i^2 = 0 \quad (\text{on développe})$$

Remplaçons β_0 par $\bar{y} - \beta_1 \bar{x}$ (trouvé à l'équation 4.1) :

$$\sum_{i=1}^{n} x_i y_i - (\bar{y} - \beta_1 \bar{x}) \sum_{i=1}^{n} x_i - \beta_1 \sum_{i=1}^{n} x_i^2 = 0$$

$$\sum_{i=1}^{n} x_i y_i - \bar{y} \sum_{i=1}^{n} x_i + \beta_1 \bar{x} \sum_{i=1}^{n} x_i - \beta_1 \sum_{i=1}^{n} x_i^2 = 0$$

Regroupons les termes en β_1 :

$$\sum_{i=1}^{n} x_i y_i - \bar{y} \sum_{i=1}^{n} x_i = \beta_1 \left(\sum_{i=1}^{n} x_i^2 - \bar{x} \sum_{i=1}^{n} x_i \right)$$

Sachant que $\sum_{i=1}^{n} x_i = n\bar{x}$, on peut réécrire :

$$\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y} = \beta_1 \left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2 \right)$$

Or, on reconnaît deux formules classiques de statistique :

— $\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$ (numérateur de la covariance)

— $\sum_{i=1}^{n} x_i^2 - n\bar{x}^2 = \sum_{i=1}^{n} (x_i - \bar{x})^2$ (numérateur de la variance)

Finalement :

$$\boxed{\beta_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2} = \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)}} \tag{4.2}$$

Formules finales de la régression linéaire simple

Les coefficients optimaux de la droite $\hat{y} = \beta_0 + \beta_1 x$ sont :

$$\beta_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \qquad \text{et} \qquad \beta_0 = \bar{y} - \beta_1 \bar{x}$$

où $\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$ et $\bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i$ sont les moyennes.

4.4 Application sur le dataset clientèle

Appliquons maintenant la régression linéaire sur le **dataset clientèle** utilisé tout au long de ce cours. Nous allons prédire la **Dépense** (y) d'un client à partir de son **Revenu** (x).